

Ejercicio de parseo de archivos FASTA

Pablo Vinuesa

2018-07-01

Contents

Presentación	1
Preparativos	1
Búsqueda y descarga de secuencias en GenBank usando el sistema ENTREZ	1
Práctica de parseo de archivos FASTA descargados de NCBI mediante ENTREZ	2
Inspección y estadísticas básicas de las secuencias descargadas	2
Edición de las cabeceras FASTA mediante herramientas de filtrado de UNIX	2
Generación automática de archivos FASTA especie-específicos (avanzado)	3

Presentación

Este código corresponde a unas prácticas escritas por Pablo Vinuesa para el manual de Bioinformática y Sistemática Molecular de la Facultad de Ciencias - UNAM, Abril 2015.

Version: 2018-07-01

Adaptada para el Taller de Filoinformática - UNLP, 2-6 Julio 2018.

Preparativos

1. genera el directorio practica2_parseo_fastas

```
### generemos un subdirectorio por debajo del que acabamos de crear y movámonos a él
mkdir -p $HOME/intro2filoinfo/lunes/practica2_parseo_fastas/data && cd $HOME/intro2filoinfo/lunes/practica2_parseo_fastas/data
```

2. Descarga el archivo recA_Bradyrhizobium_vinuesa.fa en el directorio que acabamos de generar.

Búsqueda y descarga de secuencias en GenBank usando el sistema ENTREZ

El archivo recA_Bradyrhizobium_vinuesa.fa contiene secuencias parciales (amplicones de PCR) del gen *recA* de bacterias del género *Bradyrhizobium* disponibles en GenBank. Este bloque muestra el comando usado para descargarlas. El comando debe pegarse en la ventana superior del sistema ENTREZ.

```
# pega la siguiente sentencia (sin las comillas) en la ventana de captura para interrogar la base de datos
# de NCBI mediante el sistema ENTREZ
'Bradyrhizobium[orgn] AND vinuesa[auth] AND recA[gene] '

# Una vez cargada la página, da click en el link 'send to', arriba a la derecha, y guarda en formato FASTA
# renombra el archivo sequences.fasta a recA_Bradyrhizobium_vinuesa.fa
```

Práctica de parseo de archivos FASTA descargados de NCBI mediante ENTREZ

Inspección y estadísticas básicas de las secuencias descargadas

1. ¿Cuántas secuencias hay en el archivo `recA_Bradyrhizobium_vinuesa.fa`?

```
grep -c '>' recA_Bradyrhizobium_vinuesa.fa
```

```
## 125
```

2. Veamos las 5 primeras líneas de cabeceras fasta usando `grep` y `head`

```
grep '>' recA_Bradyrhizobium_vinuesa.fa | head -5
```

```
## >EU574327.1 Bradyrhizobium liaoningense strain ViHaR5 recombination protein A (recA) gene, partial co
## >EU574326.1 Bradyrhizobium liaoningense strain ViHaR4 recombination protein A (recA) gene, partial co
## >EU574325.1 Bradyrhizobium liaoningense strain ViHaR3 recombination protein A (recA) gene, partial co
## >EU574324.1 Bradyrhizobium liaoningense strain ViHaR2 recombination protein A (recA) gene, partial co
## >EU574323.1 Bradyrhizobium liaoningense strain ViHaR1 recombination protein A (recA) gene, partial co
```

3. Cuenta el número de géneros y especies que contiene el archivo FASTA

```
grep '>' recA_Bradyrhizobium_vinuesa.fa | cut -d' ' -f3 | sort | uniq -c
```

```
##      18 canariense
##      18 elkanii
##       6 genosp.
##      28 japonicum
##      15 liaoningense
##       8 sp.
##      32 yuanmingense
```

4. Imprime una lista ordenada de mayor a menor, del número de especies que contiene el archivo FASTA

```
grep '>' recA_Bradyrhizobium_vinuesa.fa | cut -d' ' -f2,3 | sort | uniq -c | sort -nrk1
```

```
##      32 Bradyrhizobium yuanmingense
##      28 Bradyrhizobium japonicum
##      18 Bradyrhizobium elkanii
##      18 Bradyrhizobium canariense
##      15 Bradyrhizobium liaoningense
##       8 Bradyrhizobium sp.
##       6 Bradyrhizobium genosp.
```

Edición de las cabeceras FASTA mediante herramientas de filtrado de UNIX

5. Exploremos todas las cabeceras FASTA del archivo `recA_Bradyrhizobium_vinuesa.fa` usando `grep`

```
# grep '>' recA_Bradyrhizobium_vinuesa.fa | less # para verlas por página
grep '>' recA_Bradyrhizobium_vinuesa.fa | head # para no hacer muy extensa la salida
```

```
## >EU574327.1 Bradyrhizobium liaoningense strain ViHaR5 recombination protein A (recA) gene, partial co
## >EU574326.1 Bradyrhizobium liaoningense strain ViHaR4 recombination protein A (recA) gene, partial co
## >EU574325.1 Bradyrhizobium liaoningense strain ViHaR3 recombination protein A (recA) gene, partial co
## >EU574324.1 Bradyrhizobium liaoningense strain ViHaR2 recombination protein A (recA) gene, partial co
## >EU574323.1 Bradyrhizobium liaoningense strain ViHaR1 recombination protein A (recA) gene, partial co
## >EU574322.1 Bradyrhizobium liaoningense strain ViHaG8 recombination protein A (recA) gene, partial co
## >EU574321.1 Bradyrhizobium liaoningense strain ViHaG7 recombination protein A (recA) gene, partial co
```

```
## >EU574320.1 Bradyrhizobium liaoningense strain ViHaG6 recombination protein A (recA) gene, partial cds
## >EU574319.1 Bradyrhizobium yuanmingense strain ViHaG5 recombination protein A (recA) gene, partial cds
## >EU574318.1 Bradyrhizobium yuanmingense strain ViHaG4 recombination protein A (recA) gene, partial cds
```

6. simplifiquemos las cabeceras FASTA usando el comando **sed** (stream editor)

El objetivo es eliminar redundancia y los campos gb|no.de.acceso, así como todos los caracteres ‘(, ; :)’ que impedirían el despliegue de un árbol filogenético, al tratarse de caracteres reservados del formato NEWICK. Dejar solo el numero GI, así como el género, especie y cepa indicados entre corchetes.

Es decir vamos a: - reducir Bradyrhizobium a ‘B.’ - eliminar ‘RNA poly ...’ y reemplazarlo por ‘]’ - eliminar ‘genosp.’ - sustituir espacios por guiones bajos

Noten el uso de expresiones regulares como ‘.*y’[[:space:]]’

```
sed 's/|gb.*| /\|/; s/Bradyrhizobium /B./; s/genosp\ . //; s/ RNA.*\/\|/; s/[[:space:]]/_/g;' recA_Bradyrhizobium_vinuesa.faed | head
```

```
## >EU574327.1_B.liaoningense_strain_ViHaR5_recombination_protein_A_(recA)_gene,_partial_cds
## >EU574326.1_B.liaoningense_strain_ViHaR4_recombination_protein_A_(recA)_gene,_partial_cds
## >EU574325.1_B.liaoningense_strain_ViHaR3_recombination_protein_A_(recA)_gene,_partial_cds
## >EU574324.1_B.liaoningense_strain_ViHaR2_recombination_protein_A_(recA)_gene,_partial_cds
## >EU574323.1_B.liaoningense_strain_ViHaR1_recombination_protein_A_(recA)_gene,_partial_cds
```

8. Cuando estamos satisfechos con el resultado, guardamos la salida del comando en un archivo usando ‘>’ para redirigir el flujo de STDOUT a un archivo de texto

```
sed 's/ recom.*cds//; s/|gb.*| /\|/; s/Bradyrhizobium /B /; s/genosp\ . //; s/ RNA.*\/\|/; s/[[:space:]]/_/g;' recA_Bradyrhizobium_vinuesa.faed > recA_Bradyrhizobium_vinuesa.faedtab
```

Generación automática de archivos FASTA especie-específicos (avanzado)

9. Convertir archivos FASTA a formato “FASTAB” usando **perl** 1-liners.

Vamos a transformar los FASTAS de tal manera que las secuencias queden en la misma línea que su cabecera, separada de ésta por un tabulador. Esto puede ser muy útil para filtrar el archivo resultante con **grep**. Veamos un ejemplo:

```
perl -pe 'unless(/^>/){s/\n//g}; if(/^>/){s/\n\t/g}; s/>/\n>/' recA_Bradyrhizobium_vinuesa.faed | head
```

```
##
## >EU574327.1_B_liaoningense_ViHaR5 ATGAAGCTCGGCAAGAACGACCGGTCCATGGACATCGAGGCGGTGTCCTCCGGCTCGCTCGGG
## >EU574326.1_B_liaoningense_ViHaR4 ATGAAGCTCGGCAAGAACGACCGGTCCATGGACATCGAGGCGGTGTCCTCCGGCTCGCTCGGG
## >EU574325.1_B_liaoningense_ViHaR3 ATGAAGCTCGGCAAGAACGACCGGTCCATGGACATCGAGGCGGTGTCCTCCGGCTCGCTCGGG
## >EU574324.1_B_liaoningense_ViHaR2 ATGAAGCTCGGCAAGAACGACCGGTCCATGGACATCGAGGCGGTGTCCTCCGGCTCGCTCGGG
## >EU574323.1_B_liaoningense_ViHaR1 ATGAAGCTCGGCAAGAACGACCGGTCCATGGACATCGAGGCGGTGTCCTCCGGCTCGCTCGGG
## >EU574322.1_B_liaoningense_ViHaG8 ATGAAGCTCGGCAAGAACGACCGGTCCATGGACATCGAGGCGGTGTCCTCCGGCTCGCTCGGG
## >EU574321.1_B_liaoningense_ViHaG7 ATGAAGCTCGGCAAGAACGACCGGTCCATGGACATCGAGGCGGTGTCCTCCGGCTCGCTCGGG
## >EU574320.1_B_liaoningense_ViHaG6 ATGAAGCTCGGCAAGAACGACCGGTCCATGGACATCGAGGCGGTGTCCTCCGGCTCGCTCGGG
## >EU574319.1_B_yuanmingense_ViHaG5 ATGAAGCTCGGCAAGAACGACCGGTCCATGGACATCGAGGCGGTGTCCTCCGGCTCGCTCGGG
```

```
perl -pe 'unless(/^>/){s/\n//g}; if(/^>/){s/\n\t/g}; s/>/\n>/' recA_Bradyrhizobium_vinuesa.faed > recA_Bradyrhizobium_vinuesa.faedtab
```

10. Filtrar el archivo **faedtab** generado en 9 para obtener solo las secuencias de **B._yuanmingense** del mismo, guardarlo en un archivo y convertirlo de nuevo a formato FASTA.

```
grep yuanmingense recA_Bradyrhizobium_vinuesa.faedtab | head -5
```

```
## >EU574319.1_B_yuanmingense_ViHaG5 ATGAAGCTCGGCAAGAACGACCGGTCCATGGACATCGAGGCGGTGTCCTCCGGCTCGCTCGGG
## >EU574318.1_B_yuanmingense_ViHaG4 ATGAAGCTCGGCAAGAACGACCGGTCCATGGACATCGAGGCGGTGTCCTCCGGCTCGCTCGGG
## >EU574297.1_B_yuanmingense_InRo02 ATGAAGCTCGGCAAGAACGACCGGTCCATGGACATCGAGGCGGTGTCCTCCGGCTCGCTCGGG
```

```
## >EU574296.1_B_yuanmingense_InKo02    ATGAAGCTCGGCAAGAACGATCGCTCCATGGACATCGAGGCGGTCTCCTCCGGCTCGCTCGGG
## >EU574295.1_B_yuanmingense_InKo01    ATGAAGCTCGGCAAGAACGATCGCTCCATGGACATCGAGGCGGTGTCTCCTCCGGCTCGCTCGGG
grep yuanmingense recA_Bradyrhizobium_vinuesa.faedtab > recA_Byuanmingense.fnaedtab
```

11. Estas dos líneas no contienen nada nuevo en cuanto a sintaxis. Simplemente llamamos a perl para sustituir los tabuladores por saltos de línea y así reconstituir el FASTA.

```
perl -pe 'if(</>){s/\t/\n/}' recA_Byuanmingense.fnaedtab | head -5
```

```
## >EU574319.1_B_yuanmingense_ViHaG5
## ATGAAGCTCGGCAAGAACGACCGCTCCATGGACATCGAGGCGGTGTCTCCTCCGGCTCGCTCGGGCTCGATATCGCGCTCGGCATCGGCGGCTTGCCCAAGG
## >EU574318.1_B_yuanmingense_ViHaG4
## ATGAAGCTCGGCAAGAACGACCGCTCCATGGACATCGAGGCGGTGTCTCCTCCGGCTCGCTCGGGCTCGATATCGCGCTCGGCATCGGCGGCTTGCCCAAGG
## >EU574297.1_B_yuanmingense_InRo02
```

```
perl -pe 'if(</>){s/\t/\n/}' recA_Byuanmingense.fnaedtab > recA_Byuanmingense.fna
```

12. Llamar a un bucle for de shell para generar archivos fastab para todas las especies

```
for sp in $(grep '>' recA_Bradyrhizobium_vinuesa.faed | cut -d_ -f3); do
    grep "$sp" recA_Bradyrhizobium_vinuesa.faedtab > recA_B${sp}.fnaedtab
done
```

13. Veamos el resultado

```
ls *fnaedtab
```

```
## recA_Balpha.fnaedtab
## recA_Bbeta.fnaedtab
## recA_BB.fnaedtab
## recA_Bcanariense.fnaedtab
## recA_Belkanii.fnaedtab
## recA_Bjaponicum.fnaedtab
## recA_Bliaoningense.fnaedtab
## recA_Bsp.fnaedtab
## recA_Bsp..fnaedtab
## recA_Byuanmingense.fnaedtab
head -5 recA_Bjaponicum.fnaedtab
```

```
## >EU574316.1_B_japonicum_NeRa16    ATGAAGCTCGGCAAGAACGACCGGTTCGATGGATGTCGAGGCGGTGTCTCCTCCGGTTCTCTCGGGCTCG
## >EU574315.1_B_japonicum_NeRa15    ATGAAGCTCGGCAAGAACGACCGGTTCGATGGATGTCGAGGCGGTGTCTCCTCCGGTTCTCTCGGGCTCG
## >EU574314.1_B_japonicum_NeRa14    ATGAAGCTCGGCAAGAACGACCGGTTCGATGGATGTCGAGGCGGTGTCTCCTCCGGTTCTCTCGGGCTCG
## >EU574313.1_B_japonicum_NeRa12    ATGAAGCTCGGCAAGAACGACCGGTTCGATGGATGTCGAGGCGGTGTCTCCTCCGGTTCTCTCGGGCTCG
## >EU574312.1_B_japonicum_NeRa11    ATGAAGCTCGGCAAGAACGACCGGTTCGATGGATGTCGAGGCGGTGTCTCCTCCGGTTCTCTCGGGCTCG
```

14. Finalmente convertimos todos los archivos fnatabed a FASTA con el siguiente bucle for:

```
for file in *fnaedtab; do perl -pe 'if(</>){s/\t/\n/}' $file > ${file%.*}.fna; done
```

15. Visualizemos las cabeceras de dos archivos FASTA especie-específicos

```
grep '>' recA_Bjaponicum.fna | head -5
```

```
## >EU574316.1_B_japonicum_NeRa16
## >EU574315.1_B_japonicum_NeRa15
## >EU574314.1_B_japonicum_NeRa14
## >EU574313.1_B_japonicum_NeRa12
## >EU574312.1_B_japonicum_NeRa11
```

16. y confirmemos que son fastas regulares

```
head -6 recA_Bjaponicum.fna
```

```
## >EU574316.1_B_japonicum_NeRa16
## ATGAAGCTCGGCAAGAACGACCGGTCGATGGATGTCGAGGCGGTGTCCTCGGGTTCTCTCGGGCTCGACATTGCACTGGGGATCGGCGGTCTGCCCAAGG
## >EU574315.1_B_japonicum_NeRa15
## ATGAAGCTCGGCAAGAACGACCGGTCGATGGATGTCGAGGCGGTGTCCTCCGGTTCTCTCGGGCTCGACATTGCACTGGGGATCGGCGGTCTGCCCAAGG
## >EU574314.1_B_japonicum_NeRa14
## ATGAAGCTCGGCAAGAACGACCGGTCGATGGATGTCGAGGCGGTGTCCTCCGGTTCTCTCGGGCTCGACATTGCGCTGGGGATCGGCGGTCTGCCCAAGG
```